



UNIVERSIDAD DE CHILE
FACULTAD DE CIENCIAS FÍSICAS Y MATEMÁTICAS
DEPARTAMENTO DE CIENCIAS DE LA COMPUTACIÓN

Bases y análisis de discrepancias entre el discurso de los partidos políticos y la práctica de
sus representantes parlamentarios

INFORME FINAL DE CC6908 PARA OPTAR AL TÍTULO DE
INGENIERO CIVIL EN COMPUTACIÓN

Agustín Sebastián Solís Meza

MODALIDAD:
Memoria

PROFESOR GUÍA:
Valentin Barriere (DCC)
PROFESOR GUÍA 2:
Franziska Wagner (CENIA)

SANTIAGO DE CHILE
2025

1. Introducción

En una democracia representativa, la ciudadanía delega poder en organizaciones políticas que prometen defender ciertos valores, priorizar determinados temas y legislar en consecuencia. Sin embargo, no siempre existe coherencia entre lo que los partidos declaran en sus programas y lo que sus representantes efectivamente expresan o votan una vez en el Congreso. Un caso reciente en Chile lo ejemplifica: durante el debate legislativo sobre la reducción de la jornada laboral, partidos cuyos programas incluían compromisos explícitos con la agenda laboral se dividieron internamente al momento de la votación, generando cuestionamientos sobre alineamiento entre discurso, programa y acción legislativa. Fenómenos similares han sido observados en Francia, por ejemplo durante el proceso de reforma previsional, donde partidos oficialistas experimentaron quiebres internos en votaciones clave. Este tipo de discrepancias afecta la percepción de transparencia, responsabilidad política y confianza institucional.

La disponibilidad actual de corpus legislativos, votaciones, intervenciones parlamentarias y comunicaciones políticas permite estudiar estas brechas de forma sistemática mediante métodos computacionales. Los programas partidarios expresan orientaciones de largo plazo y valores ideológicos estables ([18]), pero el comportamiento discursivo cotidiano se despliega en canales diversos y con incentivos distintos: redes sociales reactivas, prensa estratégica, comisiones legislativas altamente técnicas y deliberación parlamentaria formal. La literatura ha mostrado que los partidos no enfatizan los mismos temas en todas las arenas, lo que depende de audiencias, formatos y control comunicacional ([13]). Estas diferencias abren paso a la pregunta central de este trabajo: *¿se mantiene la coherencia entre lo que un partido declara programáticamente, lo que sus representantes comunican y lo que finalmente votan?*

La comparación entre Chile y Francia permite analizar esta pregunta bajo condiciones institucionales contrastadas. Chile opera bajo un sistema presidencial con mayor autonomía de parlamentarios en la agenda legislativa; Francia combina un sistema semipresidencial donde el ejecutivo comparte poder con un primer ministro dependiente de la Asamblea, aumentando la coordinación partido–gobierno. Ello implica incentivos diferenciados para la disciplina partidaria, el costo político de desalineamiento y la probabilidad de discrepancias internas. La hipótesis de trabajo es que estas variaciones institucionales producirán patrones medibles en la coherencia política, tanto agregados (partidos) como individuales (diputados), y que estos podrán compararse de forma robusta mediante análisis textual y votacional.

Para evaluar esta hipótesis se construirá un conjunto de bases unificadas para ambos países, que permita comparar tres capas del proceso de representación: (i) contenido programático; (ii) discurso público (redes sociales y debates legislativos); y (iii) votación parlamentaria efectiva. El análisis se apoyará en marcos teóricos sobre valores morales y motivacionales ([18, 12]) y en técnicas de procesamiento de lenguaje natural como *stance detection* ([2, 3]), que permiten clasificar posturas frente a temas políticos específicos y medir cercanía o distancia entre discurso y acción.

Este proyecto se inserta en una línea de investigación emergente que busca pasar del análisis anecdótico a la medición empírica de la coherencia política. Estudios previos se han concentrado en votaciones o programas de forma aislada, pero aún es escaso el trabajo que integra canales discursivos, deliberativos y votacionales en un mismo marco comparativo. La generación de bases de datos replicables para Chile y Francia contribuye directamente a este vacío metodológico, permitiendo detectar patrones de consistencia, divergencia o ambigüedad discursiva a distintas escalas. Asimismo, el desarrollo de pipelines automatizados de extracción, clasificación y comparación habilita estudios longitudinales y monitoreo público continuo del comportamiento legislativo.

La relevancia de este estudio radica en su capacidad de aportar evidencia empírica en un campo donde a menudo predomina la percepción subjetiva. Además, ofrece la oportunidad de sistematizar y organizar información pública, al mismo tiempo que permite desarrollar herramientas de transparencia útiles para periodistas, académicos y ciudadanía. Su importancia se vuelve aún más evidente en el escenario político chileno actual, ya posterior a las recientes elecciones presidenciales y parlamentarias, donde existe un interés creciente por evaluar el grado de cumplimiento programático y la coherencia entre las promesas realizadas en campaña y el comportamiento legislativo de los representantes electos. Disponer de métricas verificables y comparables facilita este proceso de evaluación democrática y contribuye a fortalecer la rendición de cuentas y el seguimiento ciudadano de la acción política.

2. Estado del Arte

La literatura reciente sobre análisis computacional del discurso político puede organizarse en cuatro líneas principales: (i) codificación programática comparada a gran escala, (ii) modelamiento automático de postura e ideología, (iii) inferencia legislativa mediante *roll-calls*, y (iv) monitoreo institucional con herramientas basadas en modelos de lenguaje. Aunque cada área presenta avances relevantes, estas han evolucionado en paralelo sin converger en un marco integrado. Hasta donde permite identificar el conocimiento disponible, no existe aún un trabajo que combine programas partidarios, discursos parlamentarios, comunicación digital y votaciones, mucho menos uno que compare dicha coherencia entre dos sistemas institucionales con reglas distintas como Chile y Francia. Ese vacío fundamenta el aporte principal de esta memoria.

2.1. Codificación programática y análisis basado en manifiestos

El *Manifesto Project Corpus* constituye el esfuerzo más completo para sistematizar manifiestos electorales comparados, con más de 3.200 documentos en 67 países desde 1945, codificados a nivel de cuasi-frase en más de cuarenta idiomas [19]. A partir de este corpus se desarrollan modelos como *ManifestoBERTa*, entrenado sobre *XLM-RoBERTa* para clasificación de tópicos políticos en múltiples idiomas y con alta escalabilidad [16].

Para el estudio normativo subyacente a plataformas políticas, la literatura utiliza principalmente dos marcos teóricos: la Teoría de Valores Básicos de Schwartz [18], y la *Moral Foundations Theory* de Haidt [12]. Su aplicabilidad computacional ha sido validada en TouchéEval 2023–2024, donde se operacionalizan valores morales para clasificación argumentativa, evidenciando su capacidad para mapear razonamiento moral en discurso político a gran escala.

2.2. Stance detection y análisis lingüístico político

Una segunda línea relevante es el *stance detection*: clasificación automática de apoyo, rechazo o neutralidad frente a temas políticos. El dataset *CoFE* [3] y los trabajos posteriores de Stance Recognition [2] permiten inferencia *zero-shot* y *few-shot*, es decir, detección sin necesidad de entrenamiento supervisado extenso. No obstante, el foco de estos modelos es la postura discursiva, no la coherencia entre lo dicho y lo votado.

La contribución de esta memoria se diferencia explícitamente en este punto: no solo busca detectar postura, sino contrastar si los valores y posiciones expresados en discurso son consistentes con el mandato normativo declarado en los programas, ampliando el alcance conceptual de los estudios existentes.

2.3. Ideología revelada en votaciones legislativas en Chile

En Chile, el trabajo de referencia proviene de Fábrega, quien analiza la Convención Constitucional estimando posiciones ideológicas a partir del primer mes de votaciones y relacionando estas con patrones de copatrocinio [8]. El dataset longitudinal *Ideological Estimates of the Chilean Chamber of Deputies 2002–2026* [9], junto con su extensión en *Data in Brief* [10], permite escalamiento ideológico mediante DW–NOMINATE, ideal points bayesianos y modelos dinámicos.

Sin embargo, estos trabajos modelan únicamente ideología observada en votaciones. Esta tesis avanza sobre esa base al integrar votaciones, manifiestos y redes para evaluar coherencia programática multicanal, y además extiende el análisis comparativamente a Francia.

Asimismo, existen iniciativas de monitoreo legislativo orientadas a transparencia y trazabilidad pública, tales como *Ciudadanía Inteligente* [11], *Del Dicho al Hecho* [7] y *Environmental Voting Records* [20]. Si bien facilitan acceso ciudadano a información parlamentaria, estas plataformas no integran análisis semántico multicanal ni contraste con programas partidarios, y no permiten un análisis comparado entre distintos sistemas institucionales.

2.4. Infraestructura computacional para monitoreo parlamentario

El uso de modelos de lenguaje en monitoreo legislativo ha crecido aceleradamente. Seguimiento Parlamentario [1] representa uno de los esfuerzos hechos para automatizar el procesamiento de actividad legislativa, integrando web scraping de plataformas del Congreso Nacional, transcripción automática de sesiones, generación de resúmenes estructurados mediante LLMs y consulta temática con mecanismos de Retrieval-Augmented Generation (RAG). El sistema permite extraer, procesar y exponer información a través de una API, reduciendo la dependencia de trabajo manual y facilitando la trazabilidad de intervenciones y documentos legislativos a lo largo del tiempo.

A nivel técnico, existen herramientas que potencian este tipo de infraestructura computacional. Entre las utilizadas en esta memoria se encuentran BeautifulSoup para extracción y estructuración de contenido HTML [17], Faster-Whisper para transcripción de audio en alta velocidad [14], y HuggingFace Hub para descarga, versionamiento y despliegue de modelos [6]. Alternativamente, modelos como Whisper large-v3 [15] y Pyannote Speaker-Diarization 3.1 [5] permiten extender el procesamiento hacia flujos audiovisuales parlamentarios más complejos, en particular en tareas de transcripción, separación de oradores e indexación semántica. Estas herramientas constituyen la base para un pipeline de monitoreo legislativo escalable; sin embargo, ninguna aborda la medición de coherencia entre discurso programático, discurso expresado y comportamiento legislativo, vacío que esta memoria aborda directamente.

2.5. Saliencia temática y comunicación multicanal: aportes y distancia respecto a esta memoria

El estudio más cercano a este trabajo es el de Ivanusch [13], quien analiza cómo la prioridad temática de los partidos varía entre distintos canales comunicacionales. Utilizando modelos derivados de BERT, compara manifiestos, discursos parlamentarios y publicaciones en Twitter en Austria, Alemania y Suiza, mostrando que la agenda programática no se expresa de manera uniforme y que factores como la centralización comunicacional y el tipo de canal influyen en la distancia entre el ideal programático y el mensaje que finalmente circula públicamente. Su aporte es significativo porque demuestra empíricamente que los partidos no hablan de lo mismo en todas partes, y que el canal no es un contenedor neutro del discurso político.

Sin embargo, esta memoria se aparta metodológicamente de ese enfoque. Mientras Ivanusch se concentra en variaciones temáticas entre canales, aquí interesa evaluar si dichas variaciones representan coherencia o ruptura respecto de los compromisos partidarios declarados. Además, el estudio europeo no incorpora el análisis normativo basado en marcos como Schwartz [18] o Moral Foundations [12], ni considera diferencias institucionales entre sistemas legislativos. Esta investigación extiende esa línea al comparar dos contextos con reglas políticas contrastantes —Chile y Francia—, integrando cuatro fuentes simultáneas: programas partidarios, redes sociales, discursos parlamentarios y votaciones nominales, con el fin de medir convergencia programática en vez de solo saliencia temática.

2.6. Síntesis general del estado del arte

En conjunto, el estado del arte muestra que existe un alto desarrollo en análisis de manifiestos, clasificación de postura y estimación ideológica en votaciones, así como en herramientas para monitoreo legislativo. Sin embargo, estos avances han sido explorados de forma fragmentada: los manifiestos rara vez se contrastan con discurso en vivo, la postura detectada automáticamente no se evalúa frente a compromisos programáticos y las votaciones se estudian sin conectar valores, moralidad o comunicación pública. Por ello, esta memoria se plantea como un aporte integrador: analizar qué prometen los partidos, qué comunican sus representantes y qué votan efectivamente, observando si esas tres capas convergen o divergen bajo arreglos institucionales distintos, lo que permite avanzar en una medición más completa de coherencia política.

3. Objetivos

Objetivo General

Desarrollar un marco comparativo que permita medir el grado de coherencia política entre programas partidarios, discurso público y comportamiento legislativo en Chile y Francia, mediante la construcción de bases de datos integradas y el uso de procesamiento de lenguaje natural para identificar alineamientos y discrepancias tanto a nivel partidario como individual.

Objetivos Específicos

1. Recolectar y documentar cuentas oficiales de diputados y diputadas, priorizando X/Twitter como canal de uso analítico principal; registrar Instagram y otras plataformas únicamente con fines referenciales cuando existan, estableciendo una primera cobertura verificable por representante y partido.
2. Realizar una revisión institucional breve del funcionamiento legislativo en Chile y Francia (creación, discusión y votación de proyectos de ley), con el objetivo de determinar qué etapas generan evidencia comparable para análisis discursivo y qué fuentes oficiales son necesarias para construir la base de datos.
3. Identificar, mapear y evaluar disponibilidad de portales parlamentarios, APIs y repositorios oficiales en ambos países, incluyendo Congreso Nacional de Chile y Asamblea Nacional de Francia, definiendo formatos, periodicidad y profundidad de la información para su extracción posterior.
4. Construir tres bases unificadas y comparables: (i) programas partidarios; (ii) publicaciones en X/Twitter y discursos parlamentarios; (iii) votaciones nominales por representante. Estas deberán contar con limpieza textual, metadatos temporales, mapeo partido–persona y trazabilidad de fuente.
5. Aplicar modelos de análisis textual basados en teorías de valores ([18, 12]) y *stance detection* multilingüe ([3, 2]), clasificando el contenido discursivo en categorías comparables entre países y canales para estimar proximidad programática.
6. Medir de forma cuantitativa y cualitativa el grado de coherencia entre lo declarado en programas y lo expresado en discurso/votación mediante métricas de distancia semántica, alineamiento con valores y casos observacionales de desvío, reportando resultados a nivel agregado (partidos) e individual (representantes).

Evaluación

La evaluación del proyecto se realizará sobre tres dimensiones medibles:

- **Cobertura y completitud de datos:** se estimará el porcentaje de representantes incluidos por país, número total de publicaciones procesadas, número de discursos parlamentarios transcritos y proporción de votaciones vinculadas correctamente a cada legislador. El objetivo mínimo será cubrir 70 % de la Cámara en ambos países y un volumen suficiente para análisis longitudinal (estimado 10.000 publicaciones y 50 debates transcritos/segmentados).
- **Calidad y confiabilidad de las fuentes:** se verificará que todos los registros provengan de fuentes oficiales (Congreso/AN) o dominio institucional válido, asegurando trazabilidad mediante URL de origen, fecha de captura y hash de respaldo. Se considerará exitosa si los documentos poseen referencia verificable y documentada.
- **Detección efectiva de discrepancias:** se evaluará mediante métricas de alineamiento semántico entre (i) programas, (ii) discurso y (iii) votación. Se reportarán *distancias promedio entre canales*, *índices de coherencia por partido* y *desviación individual*, junto con casos cualitativos cuando la divergencia supere un umbral definido (ej., >0.25 desviación normalizada).

El éxito del trabajo se medirá por la capacidad de entregar bases de datos públicas, documentadas y replicables, además de resultados concretos que permitan evidenciar, con sustento empírico, la existencia o ausencia de discrepancias entre el mandato programático de los partidos y la práctica de sus representantes.

4. Solución Propuesta

La solución se organiza en tres niveles interconectados: (1) recolección y construcción de bases de datos, (2) procesamiento y clasificación de contenido textual y (3) análisis de discrepancias entre discurso y práctica parlamentaria, distinguiendo entre arenas de comunicación (programas, redes, parlamento) y niveles de análisis (partido vs. individuo).

4.1. Recolección y construcción de bases de datos

La primera etapa consiste en consolidar un ecosistema de datos estructurado y replicable para Chile y Francia:

- Redes sociales de diputados: se trabajará exclusivamente con publicaciones de cuentas oficiales en X/Twitter, dado que es la plataforma donde la comunicación política parlamentaria es más sistemática y fácilmente recuperable. La identificación de cuentas se realizará combinando (i) información disponible en fichas institucionales, (ii) búsqueda asistida en plataformas de monitoreo y (iii) verificación manual. La descarga histórica del contenido se realizará mediante herramientas como Zeeschuimer [4], complementada con scrapers propios cuando sea necesario.
- Programas partidarios: en Francia se utilizará el Manifesto Project Database (MPDB), que provee manifiestos codificados a nivel de cuasi-frase y metadatos electorales estandarizados [19]. En Chile, los programas se obtendrán desde los sitios oficiales de los partidos políticos inscritos y, cuando corresponda, desde repositorios documentales asociados al órgano electoral. La extracción se realizará mediante scripts en Python usando `requests` y BeautifulSoup4 [17] para descargar y parsear documentos HTML y PDF, normalizando su estructura (segmentación en secciones, etiquetas de elección y coalición) y registrando la fuente institucional en los metadatos.
- Datos parlamentarios: en Chile se utilizarán los servicios del portal de datos abiertos del Congreso Nacional para obtener: (i) listas oficiales de diputadas y diputados por período legislativo, (ii) información de proyectos de ley (boletín, título, etapa, comité) y (iii) votaciones nominales en sala. Esta información se complementará con las fichas individuales de la Cámara, que incluyen biografía, comisiones y enlaces a documentos asociados. En Francia se recurrirá a los servicios de datos de la Asamblea Nacional y al portal nacional de datos abiertos, que entregan tablas con proyectos de ley, agenda legislativa y votaciones individuales. En ambos casos se construirán tablas relacionales que enlacen personas, partidos, proyectos y votaciones, asegurando un esquema compatible entre países.

El resultado de esta etapa será un conjunto de bases de datos alineadas temporalmente, donde cada diputada o diputado queda vinculado a su partido, a sus declaraciones programáticas, a su actividad en X/Twitter y a su comportamiento legislativo.

4.2. Procesamiento y clasificación de contenido

Una vez recolectados los datos, se aplicará un *pipeline* de procesamiento de lenguaje natural orientado a dejar los textos en un formato utilizable por modelos y métricas cuantitativas.

- Limpieza, normalización y metadatos: los textos se preprocesarán para eliminar ruido técnico (marcas HTML, encabezados repetidos, artefactos de *scraping*), unificar codificación de caracteres, segmentar en unidades analíticas (por ejemplo, frases o párrafos cortos en manifiestos, tweets individuales, intervenciones en sala) y normalizar información temporal (fechas en un mismo formato). Los metadatos se utilizarán para agrupar por país, partido, persona, tipo de documento y período, construir paneles longitudinales, filtrar por tema o comisión y condicionar los análisis (por ejemplo, comparar solo comunicaciones asociadas a una determinada reforma legal). De este modo, la limpieza y estructura de los datos facilita la aplicación de modelos y la replicabilidad de los análisis posteriores.
- Proyección en marcos de valores (Schwartz y Moral Foundations): se emplearán los marcos normativos propuestos por la teoría de valores básicos de Schwartz [18] y por la Moral Foundations Theory [12] para caracterizar dimensiones valóricas presentes en los distintos canales discursivos. Siguiendo estos enfoques, se construirá un conjunto acotado de categorías aplicables al discurso político y se elaborará un pequeño conjunto de ejemplos anotados manualmente. Con ello se calibrará un modelo de clasificación basado en transformadores multilingües, capaz de asignar valores predominantes a segmentos provenientes de manifiestos, redes sociales y debates parlamentarios. El objetivo es permitir comparaciones sistemáticas entre partidos y representantes, manteniendo consistencia teórica con la literatura previa.
- Stance detection en temas legislativos específicos: siguiendo la literatura en clasificación de postura [3, 2], se adaptarán modelos multilingües para identificar apoyo, oposición o neutralidad frente a un conjunto acotado de temas de alta relevancia pública (p. ej., reforma laboral, previsional, ambiental, migración y género). Los textos asociados a cada tema (tweets, intervenciones, segmentos de manifiestos) se identificarán mediante palabras clave y metadatos legislativos. Sobre ellos se aplicará un clasificador calibrado con un conjunto reducido de ejemplos anotados, evaluado mediante métricas estándar como F1 por clase. Esto permitirá contrastar la postura expresada en programas, redes y debates con la postura revelada en las votaciones asociadas.

Este nivel produce, para cada combinación de país, partido, diputada/o y canal, un perfil cuantitativo de valores y posturas frente a temas clave, que servirá como insumo principal para el análisis de coherencia.

4.3. Análisis de discrepancias entre discurso y práctica parlamentaria

La tercera etapa consiste en medir, de manera sistemática, el grado de alineamiento o divergencia entre lo programático, lo discursivo y lo legislativo.

- Coherencia entre programas y discurso público: para cada partido se construirá, por canal (manifiestos, X/Twitter, intervenciones parlamentarias), una distribución de valores estimados y de posturas por tema. La coherencia se evaluará comparando dichas distribuciones entre canales mediante medidas de distancia entre distribuciones de probabilidad (por ejemplo, divergencia de Jensen–Shannon o distancias en el espacio de *embeddings* temáticos), siguiendo la lógica de estudios de saliencia multicanal como [13] y de clasificación programática comparada [19, 16]. El foco no estará en si los partidos hablan exactamente de los mismos temas, sino en si mantienen patrones estables de valores y posiciones normativas entre su programa y su discurso observable.
- Relación entre discurso y votaciones: en el plano legislativo, se utilizarán escalas ideológicas derivadas de votaciones nominales, como las estimaciones de puntos ideales documentadas para Chile en [9, 10], y se construirán métricas análogas para Francia siempre que los datos lo permitan. Para cada diputada/o y para cada tema legislativo definido (por ejemplo, un conjunto de leyes sobre pensiones o sobre regulación ambiental), se calculará: (i) la postura promedio expresada en su discurso (manifiestos, intervenciones, tweets) y (ii) la dirección de su voto en los proyectos correspondientes. A partir de ello se definirá un índice de incongruencia que mide la proporción de casos en que la dirección del voto es contraria a la postura expresada o a la línea programática de su partido. Se pondrá especial atención en patrones sistemáticos (por ejemplo, actores cuya tasa de incongruencia se ubique en el cuartil superior dentro de su bancada), en línea con trabajos que estudian disciplina y desviaciones legislativas a partir de *roll-calls*.
- Indicadores comparativos de coherencia: finalmente, se propondrán indicadores agregados que permitan comparar partidos y países. Entre ellos, índices de consistencia valórica (similaridad entre distribuciones de valores en programa y voto), índices de consistencia temática (coincidencia entre postura declarada y comportamiento legislativo por tema) y mapas de proximidad entre partidos contruidos a partir de *embeddings* de valores y postura, inspirados en la literatura de escalamiento ideológico y análisis programático [9, 10, 19]. Estos indicadores se utilizarán para describir patrones de coherencia o divergencia estructural, y para explorar si las diferencias institucionales entre Chile y Francia se traducen en niveles distintos de alineamiento programático.

5. Plan de Trabajo (Preliminar)

- **Recolección y construcción de bases de datos**
 - Debate parlamentario: extracción de sesiones, audios y documentos (semanas 1–3).
 - Votaciones parlamentarias: recopilación, descarga y normalización desde portales oficiales (semanas 4–5).
 - Programas partidarios: uso de MPDB (Francia) y scraping/manual (Chile) (semanas 6–7).
- **Procesamiento y clasificación de contenido**
 - Limpieza, normalización y unificación de formatos (semanas 8–9).
 - Clasificación en marcos teóricos (Schwartz, Moral Foundations) y tareas de *stance detection* (semanas 10–12).
- **Análisis de discrepancias y resultados**
 - Comparación entre programas y discursos (semanas 13–14).
 - Contraste entre discursos y votaciones, construcción de métricas de coherencia/-contradicción e identificación de casos de estudio (semanas 15–16).
- **Evaluación y redacción de memoria**
 - Evaluación global de resultados (semana 16).
 - Redacción, revisión final y entrega de la memoria (semanas 17–18).

6. Trabajo Adelantado

En esta sección se describe el trabajo práctico adelantado durante el curso CC6908, que tuvo como objetivo principal sentar las bases de infraestructura de datos y probar en pequeño algunas de las técnicas que se utilizarán en la memoria. El avance se puede agrupar en tres bloques: (i) construcción de bases consolidadas de diputadas y diputados para Chile y Francia, incluyendo sus redes sociales oficiales; (ii) organización y documentación de las fuentes y archivos de trabajo; y (iii) una prueba de concepto de diarización y transcripción automática de un fragmento de sesión parlamentaria en Chile, integrando modelos de *speech-to-text* y diarización [5, 15, 14].

6.1. Infraestructura de datos para Chile: diputadas, diputados y redes sociales

El primer bloque de trabajo consistió en desarrollar un proceso reproducible para obtener y organizar información actualizada sobre las diputadas y diputados de la Cámara de Diputadas y Diputados de Chile. La idea fue construir una base consolidada que combinara datos oficiales (nombre, partido, sexo, identificadores) con información de sus redes sociales oficiales, que no se encuentran directamente disponibles en las APIs públicas.

El flujo se dividió en dos etapas principales:

- **Extracción desde APIs oficiales del Congreso.** Se utilizaron los servicios del portal de datos abiertos del Congreso Nacional para identificar el período legislativo vigente y descargar la lista de diputadas y diputados activos en dicho período. Estos servicios entregan la información en formato XML, incluyendo nombre, apellidos, sexo y militancia política. Mediante un script en Python se descargó el XML con `requests`, se parseó con `BeautifulSoup` en modo `xml` [17] y se transformó en un *DataFrame* de `pandas` con las columnas:
 - ID: identificador único del diputado.
 - Nombre, Apellido_Paterno, Apellido_Materno.
 - Partido: nombre completo del partido.
 - Partido_Alias: sigla del partido.
 - Sexo: Masculino/Femenino, usando tanto el contenido textual como atributos auxiliares cuando fue necesario.

Con ello se generó un archivo `lista_diputados.csv`, que recoge la lista oficial de 155 diputadas y diputados del período 2022–2026, tomando siempre la militancia más reciente registrada en el XML para representar el partido actual de cada parlamentario.

- **Scraping de redes sociales desde las fichas individuales.** Una vez construida la base oficial, se desarrolló un *scraper* en Python usando `BeautifulSoup4` [17] para complementar la información con redes sociales oficiales. Cada diputada o diputado tiene una ficha pública en el sitio de la Cámara, que incluye un bloque denominado “Sitio web y redes sociales” con enlaces a plataformas como Facebook, X/Twitter, Instagram, YouTube, TikTok, LinkedIn y sitios web personales o institucionales.

El script recorre las fichas a partir de la columna ID, localiza el bloque correspondiente en el HTML y extrae todos los enlaces, clasificándolos automáticamente por plataforma

mediante expresiones regulares y palabras clave en el texto (por ejemplo, dominios específicos o nombres de redes). Para evitar problemas de bloqueo, se incluyeron *headers* de navegador, pausas aleatorias entre solicitudes y un sistema de reintentos en caso de errores o respuestas incompletas.

Los resultados se integraron al *DataFrame* original, agregando columnas como Facebook, X, Instagram, YouTube, TikTok, LinkedIn y Web, y se exportaron en el archivo `lista_diputados_redes.csv`. De este modo, se obtuvo un dataset final que combina datos oficiales del Congreso con las principales redes sociales públicas de los 155 representantes.

En el proceso se utilizaron las librerías `requests`, `BeautifulSoup4` [17], `pandas`, `tqdm` (para visualizar el progreso del scraping) y `re` (para clasificación y limpieza de enlaces), además de un montaje de Google Drive en Google Colab para gestionar los archivos.

6.2. Infraestructura de datos para Francia

El segundo bloque replicó la lógica de Chile, pero adaptado al contexto francés, donde parte de la información está disponible directamente en formato tabular a través de los servicios de datos abiertos de la Asamblea Nacional. A partir de estos datos se construyó una primera base con identificadores, nombres y afiliación partidaria de las diputadas y diputados en ejercicio.

El foco principal del trabajo adelantado en Francia fue la obtención y estandarización de las redes sociales de las y los diputados. Para ello se programó un *scraper* similar al chileno, pero apuntando a las fichas individuales del sitio de la Asamblea Nacional francesa, cuyas páginas de perfil incluyen botones de redes sociales en bloques específicos (por ejemplo, menús laterales o listas verticales de enlaces).

El script recorre la lista de identificadores, descarga cada página con `requests`, identifica el bloque de redes sociales con `BeautifulSoup4` y clasifica los enlaces en columnas como Twitter, Facebook, Instagram, LinkedIn, YouTube, TikTok y Site. Al igual que en el caso chileno, se incorporaron pausas y reintentos para evitar ser bloqueado por el servidor y se evitó reescribir filas que ya contaban con datos, lo que permite reanudar el proceso sin perder progreso.

En una fracción de casos, los enlaces no aparecían en los bloques oficiales de redes sociales; para ellos se realizó una búsqueda manual asistida utilizando fuentes complementarias especializadas en seguimiento parlamentario (por ejemplo, plataformas de monitoreo ciudadano y sitios que agregan información de actividad legislativa), con el fin de completar la información faltante. El resultado se almacenó en un archivo `deputes_france_redes.csv` y en una hoja de cálculo principal, que servirá como base para los análisis posteriores.

6.3. Organización y documentación de la infraestructura de datos

Además del código, se trabajó en la organización del material en una estructura clara de carpetas en Google Drive, pensada para facilitar el versionamiento y el trabajo colaborativo futuro. La estructura general es:

- Un directorio para Chile, que contiene la documentación del proceso, los archivos con la lista oficial de diputadas y diputados, la versión enriquecida con redes sociales, un archivo de hoja de cálculo principal, los `notebooks` de scraping y una subcarpeta con los archivos derivados del dataset de Fábrega sobre la Cámara de Diputados chilena [9, 10].
- Un directorio para Francia, que incluye un `Readme` análogo y el archivo con la lista de diputados y redes sociales para la Asamblea Nacional francesa.
- Un directorio para la propuesta de memoria, con la versión en PDF y los documentos fuente en `LATEX`.

Adicionalmente, se consolidó un inventario de fuentes institucionales y herramientas externas para ambos países, agrupado en secciones como *datos en bruto*, *sitios institucionales*, *herramientas* y *datasets*. Para Chile, esto incluye los portales de la Cámara de Diputadas y Diputados, los servicios de proyectos de ley, votaciones en sala, sesiones, el portal de datos abiertos del Congreso Nacional, así como herramientas externas como el proyecto de seguimiento automatizado de actividad parlamentaria [1], servicios de extracción de texto desde X/Twitter y el dataset de Fábrega [9]. Para Francia, se consideran tanto las fuentes oficiales de la Asamblea Nacional como recursos complementarios que agregan y procesan información sobre la actividad legislativa.

Finalmente, se documentaron recursos adicionales que serán clave para las etapas posteriores de la memoria, como modelos de transcripción de audio (`whisper` [15]), modelos de diarización de hablantes (`pyannote/speaker-diarization-3.1` [5]) y otros modelos distribuidos a través de la plataforma de Hugging Face [6].

6.4. Prueba de concepto: diarización y transcripción de una sesión en Chile

El último bloque del trabajo adelantado fue una prueba de concepto orientada a evaluar la viabilidad técnica de extraer de forma automática “quién dijo qué” en los debates parlamentarios, combinando diarización de hablantes y transcripción automática. Para ello se trabajó con un fragmento específico de una sesión especial de la Cámara.

- **Recorte y preprocesamiento de audio.** A partir del video original de la sesión se extrajo solo un segmento acotado de la discusión (del orden de diez minutos), usando `ffmpeg` para generar un archivo de audio mono a 16 kHz, formato recomendado para los modelos de diarización. Esto redujo el problema a un fragmento manejable en GPU dentro de Google Colab.
- **Diarización de hablantes con `pyannote`.** Sobre el fragmento resultante se aplicó el modelo de diarización `pyannote/speaker-diarization-3.1` [5], descargado desde Hugging Face y utilizado a través de la librería `pyannote.audio`. Se configuró el *pipeline* para trabajar con GPU (cuando disponible) y se restringió el número de hablantes a cuatro (tres diputados y un moderador), de acuerdo con el contenido conocido del segmento. El modelo entregó una secuencia de segmentos etiquetados como `SPEAKER_00`, `SPEAKER_01`, `SPEAKER_02` y `SPEAKER_03`, cada uno con tiempos de inicio y término precisos, siendo estos Speakers fácilmente asociables a los diputados correspondientes mediante el video de Youtube.
- **Transcripción automática con `Whisper`/`Faster-Whisper`.** En paralelo, se transcribió el mismo fragmento usando el modelo `Whisper` [15] en su implementación optimizada `Faster-Whisper` [14], que permite aprovechar aceleración por GPU para segmentar y transcribir el audio. Se utilizó un modelo de tamaño intermedio, generando una lista de segmentos con `start`, `end` y `text`, manteniendo marcas de tiempo suficientemente finas como para alinear con la diarización.
- **Alineación de segmentos y construcción de una tabla “quién dijo qué”.** A partir de las dos salidas anteriores (diarización y transcripción), se implementó una rutina de alineación simple: para cada segmento de hablante se recopilan los segmentos de texto cuya ventana temporal cae completamente dentro del intervalo de ese hablante. El texto de esos segmentos se concatena, produciendo una tabla final con columnas `speaker`, `start`, `end` y `text`. Este resultado se exportó a un archivo `diarizacion_con_texto.csv`, que constituye una primera demostración de la posibilidad de trabajar con debates parlamentarios a nivel de intervenciones individuales, sin anotar manualmente todo el audio.

Esta prueba de concepto, aunque acotada a un solo fragmento, muestra que es técnicamente factible integrar modelos de diarización y transcripción para obtener datos estructurados sobre quién habla, durante cuánto tiempo y qué dice. En etapas posteriores de la memoria se deberá mejorar la alineación, evaluar la calidad de la transcripción en dominios específicos (términos jurídicos, nombres propios) y vincular cada identificador de hablante con un actor concreto (diputado o autoridad de la mesa), pero el avance realizado ya ofrece una base concreta sobre la cual iterar.

6.5. Síntesis y próximos pasos

En conjunto, el trabajo adelantado permitió (i) construir y documentar bases de datos consolidadas de diputadas y diputados para Chile y Francia mediante web scrapers especializados, integrando datos provenientes de APIs oficiales y páginas institucionales; (ii) organizar la infraestructura de archivos y fuentes en una estructura replicable que facilita la ejecución continua de los procesos; y (iii) validar, mediante una prueba de concepto, la factibilidad técnica de aplicar modelos de diarización y transcripción automática para transformar fragmentos de debates parlamentarios en datos estructurados.

Estos avances sientan una base sólida para la memoria: la infraestructura de datos obtenida mediante extracción automatizada y limpieza sistemática permite articular un análisis comparado entre países y entre distintas arenas de comunicación política. Del mismo modo, la prueba de concepto en audio demuestra que es técnicamente viable identificar hablantes, segmentar intervenciones y recuperar texto a nivel de turno de palabra, habilitando futuros análisis de valores, posturas y patrones discursivos directamente desde sesiones parlamentarias.

En la siguiente etapa, el foco estará en completar la fase de recolección masiva, que constituye el último componente crítico antes del análisis. Esto incluye: (i) sistematizar la descarga completa de debates legislativos en ambos países; (ii) automatizar la recolección y estandarización de votaciones nominales y proyectos de ley; (iii) finalizar la obtención de publicaciones en redes sociales de todos los parlamentarios activos; y (iv) consolidar estos elementos en un ecosistema unificado, alineado temporalmente y listo para procesamiento semántico.

Con esta capa de datos plenamente consolidada, el proyecto quedará en posición de avanzar hacia su fase central: aplicar modelos de clasificación de valores y *stance detection*, construir métricas cuantitativas de coherencia programática y evaluar sistemáticamente la relación entre lo que los partidos declaran, lo que sus representantes comunican y lo que finalmente hacen al votar.

Referencias

- [1] Acevedo, Diego: *Seguimiento Parlamentario*. <https://github.com/diego-acevedo/seguimiento-parlamentario>, 2025. GitHub repository, CC BY 4.0.
- [2] Barriere, Valentin y Alexandra Balahur: *Multilingual Multi-target Stance Recognition in Online Public Consultations*. *Mathematics*, 11(9):2161, 2023. <https://www.mdpi.com/2227-7390/11/9/2161>.
- [3] Barriere, Valentin y Guillaume Jacquet: *CoFE: A New Dataset of Intra-Multilingual Multi-target Stance Classification from an Online European Participatory Democracy Platform*. En *Proceedings of the 2nd Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 12th International Joint Conference on Natural Language Processing (ACL-IJCNLP)*, 2022.
- [4] Bouchet-Valat, Milan: *Zeeschuimer: Twitter/X historical data extractor*. <https://github.com/rudeboybert/zeeschuimer>, 2024. Herramienta de código abierto para extracción histórica de publicaciones en X/Twitter.
- [5] Bredin, Hervé y collaborators: *pyannote/speaker-diarization-3.1*. <https://huggingface.co/pyannote/speaker-diarization-3.1>, 2023. Modelo de diarización de hablantes basado en pyannote.audio.
- [6] Debut, Lysandre, Thomas Wolf y cols.: *The Hugging Face Hub*. <https://huggingface.co>, 2023. Plataforma para compartir modelos de lenguaje y audio.
- [7] Espacio Público: *Del Dicho al Hecho – Seguimiento de cumplimiento programático legislativo*, 2018. <https://deldichoalhecho.cl/>, Plataforma de análisis de compromisos legislativos y nivel de cumplimiento.
- [8] Fábrega, Jorge: *Ordenamiento Ideológico en la Convención Constitucional Chilena*. *Revista de Ciencia Política*, 42(1):127–151, 2022.
- [9] Fábrega, Jorge: *Ideological Estimates of the Chilean Chamber of Deputies, 2002–2026*, 2025.
- [10] Fábrega, Jorge: *Ideological positions in the Chilean Chamber of Deputies (2002–2026): A legislative roll-call dataset*. *Data in Brief*, 2025.
- [11] Fundación Ciudadanía Inteligente: *Ciudadanía Inteligente – Plataforma de Transparencia y Fiscalización Legislativa*, 2010. <https://ciudadaniai.org/>, Iniciativa de datos abiertos para seguimiento de actividad parlamentaria en Chile.
- [12] Graham, Jesse, Jonathan Haidt, Sena Koleva, Matt Motyl, Ravi Iyer, Sean P. Wojcik y Peter H. Ditto: *Moral Foundations Theory: The Pragmatic Validity of Moral Pluralism*. En *Advances in Experimental Social Psychology*, volumen 47, páginas 55–130. Academic Press, 2013.
- [13] Ivanusch, Christoph: *Where do parties talk about what? Party issue salience across com-*

munication channels. West European Politics, 48(3):618–644, 2024.

- [14] Klein, Guillaume: *Faster-Whisper*. <https://github.com/SYSTRAN/faster-whisper>, 2023. Implementación optimizada de Whisper para inferencia rápida.
- [15] OpenAI: *Whisper large-v3*. <https://huggingface.co/openai/whisper-large-v3>, 2023. Modelo de transcripción de voz multilingüe.
- [16] Rathje, Eric, Muhammad Imran y Julia Fuchs: *ManifestoBERTa: Scaling multilingual policy text classification*. Proceedings of the ACL Political Text Workshop, 2024. Modelo basado en XLM-RoBERTa entrenado sobre Manifesto Project Corpus.
- [17] Richardson, Leonard: *Beautiful Soup Documentation*. <https://www.crummy.com/software/BeautifulSoup/>, 2023. Librería de Python para análisis de documentos HTML y XML.
- [18] Schwartz, Shalom H.: *An Overview of the Schwartz Theory of Basic Values*. Online Readings in Psychology and Culture, 2(1):1–20, 2012.
- [19] Volkens, Andrea, Werner Krause, Pola Lehmann, Sven Regel y Bernhard Weßels: *Manifesto Project Corpus*, 2024. <https://manifesto-project.wzb.eu/>, Versión 2024, base comparada de manifiestos políticos.
- [20] Votaciones Ambientales: *Environmental Voting Records – Observatorio de Votaciones Ambientales en el Congreso*, 2022. <https://votacionesambientales.cl/parlamentario/>, Base de datos temática que clasifica votos parlamentarios por impacto ambiental.